

对比跨域序列推荐论文复现报告

颜杰

2023/12/08

摘要

跨域序列推荐 (Cross-domain Sequential Recommendation, CDSR) 旨在基于用户对多个领域的历史交互序列来预测用户未来可能交互的物品。原论文 [1] 提到, CDSR 的关键挑战是如何集合序列内和序列间的物品交互以挖掘精准的跨域用户偏好。现有工作首先只是学习具有序列内物品交互的单域用户偏好, 然后构建一个迁移模块获得跨域用户偏好。但是, 这种迁移和隐式的解决方案可能会受到设计的迁移模块性能瓶颈的限制, 并且这种方式还忽略了序列间的物品关系。而复现论文提出了 C^2DSR 解决上述问题以获得准确的用户偏好。其主要思想是同时利用序列内和序列间的物品关系, 共同学习单域和跨域的用户偏好。具体来说, 首先利用图神经网络挖掘序列内物品关系, 然后使用注意力编码器来捕获物品序列关系, 在此基础上, 设计了两种不同的序列训练目标获得用户单域和跨域表示, 此外, 提出了对比跨域最大化信息目标, 通过最大化互信息来增强单域和跨域用户表示的相关性。为了验证 C^2DSR 的有效性, 作者处理了数据集的数据泄露问题, 并重新划分了这三个数据集, 通过实验验证 C^2DSR 的有效性。本文认为物品的文本信息在一定程度上能够帮助提升性能, 因此在此复现论文基础上, 首先在原论文提供的数据集上复现了 C^2DSR 的对比实验效果, 使用 MGCL [18] 模型论文中发布的数据集进行实验, 引入物品的文本描述信息, 尝试改进, 并最终验证了文本有助于增强物品表示, 在一定程度上提升了推荐性能。

关键词: 跨域序列推荐; 对比学习; 文本描述

1 引言

为了对用户的动态偏好进行建模, 序列推荐 (Sequential Recommendation, SR) 旨在根据用户过去的序列交互向用户推荐下一个物品。相较于不考虑用户对物品的交互先后顺序, 根据用户的交互物品顺序进行推荐通常而言性能更优。

但是只考虑单个领域只能捕获用户的部分偏好, 不同平台的同一个用户可以表现出不同的偏好, 与此同时, 如果一个用户在一个领域的交互物品过少, 数据量不够, 那么很难为用户推荐满意的物品, 为了能够为了缓解以上问题, 跨域推荐旨在通过利用来自其他相关领域的丰富信息, 能够提升本领域的推荐性能。以下借用论文给出的示意图来阐述。图 1 中给出了一个用户在两个领域上交互序列, 分别是电影和图书领域, 用户最近观看了电影《指环王》, 接下来阅读了书籍《指环王》。如果我们只考虑用户在图书领域的交互, 直观上理解, 不可能推荐《指环王》这本书给用户, 因为在单一的图书域中没有明确的类似交互反映《指

环王》的偏好。这是因为用户在每个单一领域中的历史交互可能只反映了部分偏好，容易使推荐系统在不完整（或单一领域）的偏好上产生偏差。但是如果，我们借助图书领域的用户交互历史序列，将两个领域的用户偏好结合，就能够为用户推荐出更满意的物品。

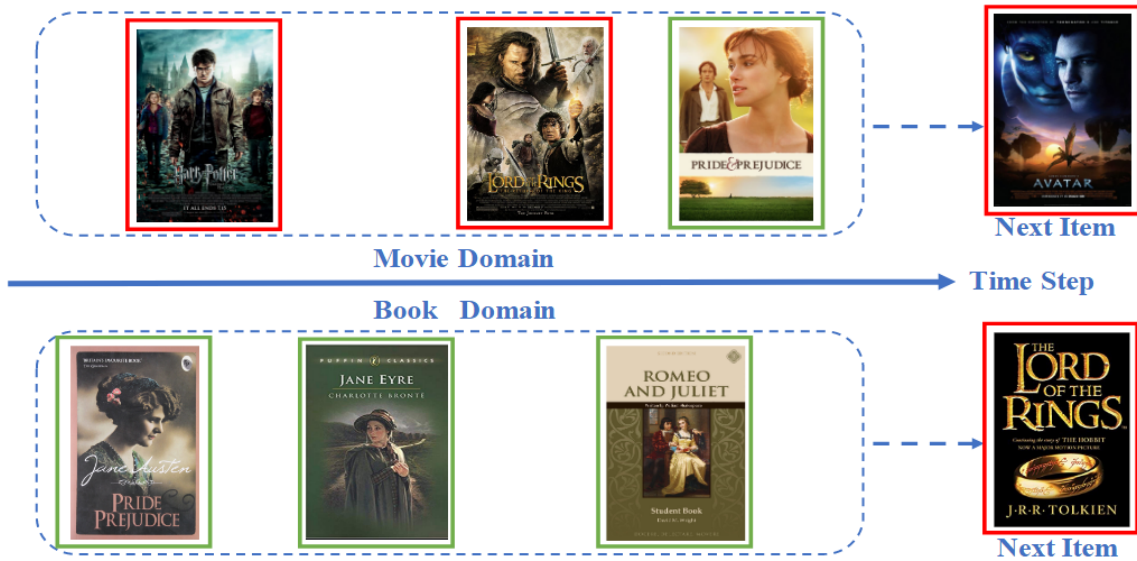


图 1. 用户在电影和图书域的交互序列示例，来源论文 [1]

与复现的论文相关的工作主要有 π -net [11]，MIFN [12]。 π -net [11]是先通过对每个单域中的物品交互序列建模来生成单域表示，然后通过门控转移模块将学习到的单域表示转移到其他域中。MIFN [12]为了增强网络中的转移模块，进一步引入了外部知识图谱转移模块，以引导不同领域物品之间的连接。

以上两个模型均首先通过单独学习单领域用户偏好，但这通常会产生有领域偏见的用户表征。仅仅转移有偏差的单领域偏好来描述精确的跨领域用户偏好是难以实现的，这很容易导致不稳定和次优的推荐结果。因此，有必要联合学习单域和跨域用户偏好，以实现无偏见的信息传递。以往的工作只关注序列内物品关系建模，捕捉序列模式信号以获得序列表示，却忽略了两个领域的物品间的序列关系，而这种关系也能够生成更好的用户表示。

因此，C²DSR [1]从同时捕捉序列内和序列间的物品关系来进行表征学习入手，并结合对比互信息最大化目标，提出了一种对比跨域序列推荐模型。该模型在MIFN [12]发布的数据集上实验，并与现有的CDSR模型，表现出最佳的性能。本文首先验证了在原数据集上的模型性能，并迁移模型到MGCL [18]的数据集上进行实验，并在此基础上引入物品文本描述信息，结果证明，物品文本描述信息在一定程度上提升了推荐性能。

2 相关工作

在这一节中，将从以下分类中介绍相关工作：（1）跨域推荐；（2）序列推荐；（3）跨域序列推荐；

2.1 跨域推荐

跨域推荐（Cross-Domain Recommendation, CDR）旨在通过结合用户在不同领域的交互数据，学习用户在不同领域的偏好，从而提升单个领域或多个领域的预测效果。CMF [14]是一种基于用户多域交互数据的经典方法，该方法通过将多个领域交互矩阵分解，共享用户潜在可能的偏好行为。CoNet [7]使用深度神经网络实现了一个交叉协作网络，实现了知识在两个领域上的跨域迁移。BiTGCF [10]在两个领域上分别使用图卷积神经网络学习用户在不同领域的偏好，并设计了一个跨域迁移模块在域间迁移知识。虽然这类方法考虑了用户在不同领域的偏好，但并没有考虑到用户的对物品交互的先后顺序。

2.2 序列推荐

序列推荐（Sequential Recommendation, SR）旨在通过最新的历史交互序列对用户的动态偏好进行建模，以预测其未来可能交互的物品。有的工作有将循环神经网络用于推荐领域 [5]，还有的工作将卷积神经网络用于序列推荐，Caser [16]是这一经典方法，Caser分别采用水平和垂直卷积的方式建模序列，从而进行信息提取。在序列推荐的另一种代表技术是使用注意力机制对序列进行建模，如经典模型SASRec [8]，因该方法较早使用了注意力进行序列推荐，使其成为了目前大多数的序列推荐方法需要进行对比的基线模型。SR-GNN [17]使用了图卷积神经网络对用户的交互行为构建有向图，融合了序列中物品向量表征表示为用户的表征向量，从而进行推荐。传统的推荐范式是基于ID来实现的，但是基于ID的方法高度依赖于交互数据，IDA-SR [13]提出了一种基于文本表示的序列推荐方法，该方法从物品的文本描述信息中学习物品表示，替代了传统的ID表示物品。但是，这类方法均局限某一个平台或数据集，并没有考虑到迁移其他领域的知识来提升序列推荐的性能。

2.3 跨域序列推荐

跨域序列推荐（CDSR）是一种结合了多个领域的数据源、知识，并考虑到了用户的动态偏好的推荐方法。早期的工作 π -net [11]通过精心设计的门控单元实现了在共享账户场景的知识迁移。MIFN [12]通过构建知识图谱，将用户行为和物品信息结合，实现了知识的跨域流动。DA-GCN [3]使用图卷积神经网络将多个领域的用户和物品构建为一个图，然后设计了一个领域感知的图卷积网络来学习用户特定的节点表示，并为了充分考虑用户对项目的领域特定偏好，引入注意力机制，以选择性地引导信息传递过程。UnisRec [6]使用物品的文本信息作为物品的特征表示，由于文本并没有ID只能局限于单个域，因此文本能够很好的实现跨域迁移知识。MGCL [18]提出了一种多视图图对比框架，在单域和跨域场景构建图，分别学习用户的单域动态偏好和用户多域固有特征，并使用对比学习从不同域捕获用户偏好的互补信息。

3 本文方法

3.1 本文方法概述

在本节中，对复现论文的工作进行概述，并介绍本文中提出的改进模块。主要包括如下部分：（1）图和注意力编码器（2）序列训练目标（3）对比信息最大化目标（4）模型训练和

3.2 符号定义

对于跨域场景，每个交互序列涉及两个领域，即领域 X 和领域 Y ，设 S 表示整个交互序列集合，其中每个实例 $(S^X, S^Y, S)_u \in \mathcal{S}$ ，对于每个实例， $S^X = [x_1, x_2, \dots, x_{|S^X|}]$ 和 $S^Y = [y_1, y_2, \dots, y_{|S^Y|}]$ 表示对应的单域交互序列， $S = [y_1, x_1, x_2, \dots, y_{|S^Y|}, \dots, x_{|S^X|}]$ 表示通过对 S^X 和 S^Y 领域按时间顺序合并的跨域交互序列，其中每个 $x \in \mathcal{X}$ 和 $y \in \mathcal{Y}$ 都是交互过的物品，注意 \mathcal{X} 和 \mathcal{Y} 分别表示的是 X 和 Y 领域的整个物品集合。为了简单表示，引入三个有向的物品-物品矩阵， $A^X \in \{0, 1\}^{|\mathcal{X}| \times |\mathcal{X}|}$ ， $A^Y \in \{0, 1\}^{|\mathcal{Y}| \times |\mathcal{Y}|}$ ， $A \in \{0, 1\}^{(|\mathcal{X}|+|\mathcal{X}|) \times (|\mathcal{Y}|+|\mathcal{Y}|)}$ 来表示 \mathcal{S} ，其中，如果 x_j 是 x_i 的下一个物品，那么 $A_{ij}^X = 1$ ，否则 $A_{ij}^X = 0$ 。

给定一个观测到的交互序列 $(S^X, S^Y, S)_u$ ，对于跨域推荐的目标是可以分别在两个领域上预测下一个物品，公式表示如下：

$$\begin{aligned} & \operatorname{argmax}_{x_i \in \mathcal{X}} P^X(x_i | S^X, S^Y, S), \text{ if next item } \in \mathcal{X} \\ & \operatorname{argmax}_{y_j \in \mathcal{Y}} P^Y(y_j | S^X, S^Y, S), \text{ if next item } \in \mathcal{Y} \end{aligned} \quad (1)$$

其中， $P^X(x_i | S^X, S^Y, S) \in \mathbb{R}^{|\mathcal{X}|}$ 和 $P^Y(y_j | S^X, S^Y, S) \in \mathbb{R}^{|\mathcal{Y}|}$ 是候选物品的概率，其中最高的一个被选择作为下一个推荐物品。

3.3 图和注意力编码器

3.3.1 嵌入初始化层

在嵌入映射阶段，为了获得两个单域和跨域的物品交互序列的初始化的物品表示，引入了三个参数矩阵 $E^X \in \mathbb{R}^{|\mathcal{X}| \times d}$ ， $E^Y \in \mathbb{R}^{|\mathcal{Y}| \times d}$ ， $E \in \mathbb{R}^{(|\mathcal{X}|+|\mathcal{Y}|) \times d}$ ，其中， d 是嵌入的维度。另外，为了能够学习到序列的有序信息，定义一个可学习的参数位置嵌入矩阵 $T \in \mathbb{R}^{M \times d}$ 增强输入到自注意力模块的物品嵌入 [2]，其中 M 是最大的序列交互长度，如 $M = 30, 100$ 。

3.3.2 图神经网络模块

受到研究 [4]的启发，对序列使用图神经网络建模 [9]，移除了所有的卷积矩阵乘法和非线性激活函数，以更好的捕获协同信号。具体而言：给定如下物品-物品矩阵： A^X ， A^Y ， A 和初始化后的嵌入 $G_0^X = E^X$ ， $G_0^Y = E^Y$ ， $G_0 = E$ ，可以得到：

$$G_1^X = \operatorname{Norm}(A^X)G_0^X, G_1^Y = \operatorname{Norm}(A^Y)G_0^Y, G_1 = \operatorname{Norm}(A)G_0. \quad (2)$$

其中， $\operatorname{Norm}(\cdot)$ 表示行归一化函数，行归一化类似于LightGCN [4]， G_1^X ， G_1^Y ， G_1 是卷积输出。通过堆叠 L 层，可以得到一系列的输出， $\{G_0^X, \dots, G_L^X\}$ ， $\{G_0^Y, \dots, G_L^Y\}$ ， $\{G_0, \dots, G_L\}$ ，使用 $\operatorname{Mean}(\cdot)$ 函数来平均堆叠的输出，物品的表示如下所示：

$$G^X = \operatorname{Mean}(G_l^X) + E^X, G^Y = \operatorname{Mean}(G_l^Y) + E^Y, G = \operatorname{Mean}(G_l) + E. \quad (3)$$

3.3.3 自注意力模块

原文中将SASRec [8]作为一个模块提取序列中物品关系。原文在输入序列¹上使用了填充技术，整体编码过程公式化为：

$$H^X = \text{AttEncoder}^X(S^X, G^X), H^Y = \text{AttEncoder}^Y(S^Y, G^Y), H = \text{AttEncoder}(S, G) \quad (4)$$

其中， $H^X \in \mathbb{R}^{|S| \times d}$ ， $H^Y \in \mathbb{R}^{|S| \times d}$ ， $H \in \mathbb{R}^{|S| \times d}$ 是序列输出。

3.4 序列训练目标

在本节中，在上节中生成了序列输出 H^X, H^Y, H 后，使用两个序列目标来优化他们作为单域和跨域的代表，如图2所示。

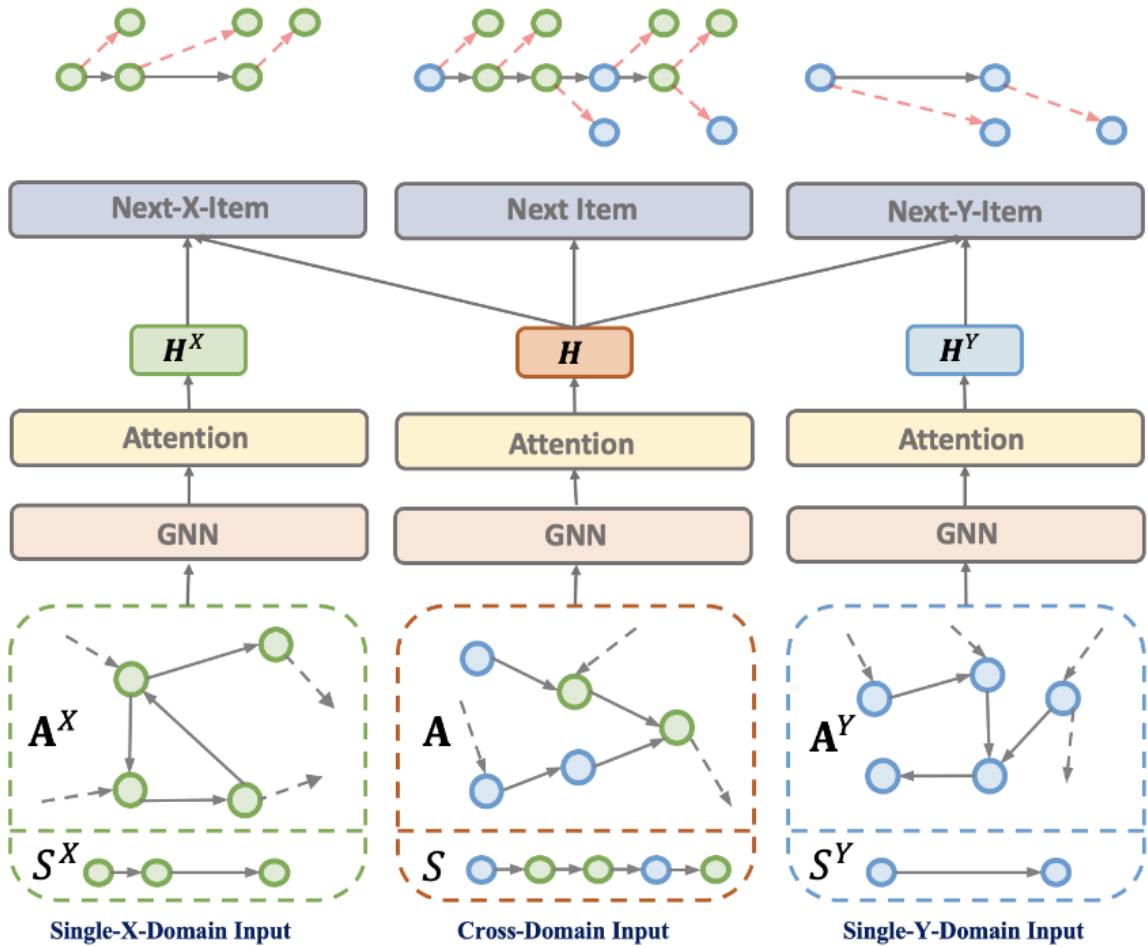


图 2. 模型总体示意图，其中红色虚线表示预测的下一个物品，引用来自 [1]

3.4.1 单域物品预测

对于单域物品的预测，最常见的就是训练模型直接基于用户的历史交互序列推荐下一个物品，以X域为例，给定一个单域有填充的交互序列， $S^X = [<\text{pad}>, x_1, x_2, <\text{pad}>, \dots, x_t]$,

¹在相应的位置上放置<pad>物品，以便从S上分离单域序列 S^X 和 S^Y 。例如， $S^X = [<\text{pad}>, x_1, x_2, <\text{pad}>, x_3]$ ， $S^Y = [y_1, <\text{pad}>, <\text{pad}>, y_2, <\text{pad}>]$ ， $S = [y_1, x_1, x_2, y_2, x_3]$ ，其中用常数零向量0作为<pad>物品的嵌入。

下一个预测物品为 x_{t+1} ，使用通用的训练策略优化编码器：

$$\mathcal{L}_{\text{single}}^X = \sum_{S^X \in \mathcal{S}} \sum_t \mathcal{L}_{\text{single}}^X(S^X, t) \quad (5)$$

$$\mathcal{L}_{\text{single}}^X(S^X, t) = -\log P_{\text{single}}^X(x_{t+1} | [< \text{pad} >, x_1, x_2, < \text{pad} >, \dots, x_t])$$

其中，概率 $P_{\text{single}}^X(x_{t+1} | [< \text{pad} >, x_1, x_2, < \text{pad} >, \dots, x_t])$ 与向量空间中所有物品 $x \in \mathcal{X}$ 和给定序列之间的相似性成正比。根据学习到的 H^X 和 H 表示，计算单域预测概率 $P_{\text{single}}^X(\cdot)$ 的方法如下所示（Y领域计算方法类似）：

$$P_{\text{single}}^X(x_{t+1} | [\dots, x_t]) = \text{Softmax}(\mathbf{h}_t^X W^X + \mathbf{h}_t W^X)_{x_{t+1}} \quad (6)$$

其中， $\mathbf{h}_t^X \in \mathbb{R}^{1 \times d}$, $\mathbf{h}_t \in \mathbb{R}^{1 \times d}$ 是在位置 t 的序列表示， $W^X \in \mathbb{R}^{d \times |\mathcal{X}|}$ 是用于预测的可学习的参数矩阵。具体而言， $\text{Softmax}(\mathbf{h}_t^X W^X + \mathbf{h}_t W^X) \in \mathbb{R}^{|\mathcal{X}|}$ 是所有物品的非负预测概率，其总和为1，选择相应的概率 x_{t+1} 作为最终的预测分数。公式(5-6)一样用于单个Y领域，即 L_{single}^Y 。

3.4.2 跨域物品预测

复现论文作者认为，在跨域上，也需要一个平衡的目标函数，希望模型同时在两个领域上的预测能力都能够有所提升，对于跨域物品 S 的训练预测如下：

$$\mathcal{L}_{\text{cross}} = \sum_{S \in \mathcal{S}} \sum_t \mathcal{L}_{\text{cross}}(S, t), \quad (7)$$

$$\mathcal{L}_{\text{cross}}(S, t) = \begin{cases} -\log P_{\text{cross}}^X(x_{t+1} | [y_1, x_1, x_2, \dots, x_t]), \\ -\log P_{\text{cross}}^Y(y_{t+1} | [y_1, x_1, x_2, \dots, x_t]), \end{cases}$$

其中， $P_{\text{cross}}^X(\cdot)$, $P_{\text{cross}}^Y(\cdot)$ 是利用 H 得到的：

$$P_{\text{cross}}^X(x_{t+1} | [y_1, x_1, x_2, \dots, x_t]) = \text{Softmax}(\mathbf{h}_t W^X)_{x_{t+1}}, \quad (8)$$

$$P_{\text{cross}}^Y(y_{t+1} | [y_1, x_1, x_2, \dots, x_t]) = \text{Softmax}(\mathbf{h}_t W^Y)_{y_{t+1}},$$

其中， W^X 是这个相同的参数矩阵在 $P_{\text{cross}}^X(\cdot)$ 。在公式(7)中，将域X和Y的损失函数分解为两个相等的独立部分进行优化，即使交互序列在另一个域中包含许多连续的物品，也可以保持对一个域的预测能力。

到目前为止，已经介绍了单领域和跨领域的序列物品预测目标。如图2所示，通过学习到的表示，这两种类型的目标具有完全不同的目的。其中， H^X ， H^Y 仅用于预测下一个单域物品， H 旨在预测两个域的物品。因此，通过优化公式(5)和公式(7)，使 H^X ， H^Y 倾向于学习单域用户偏好， H 学习跨域用户偏好。

3.5 对比信息最大化目标

由于单域表示 H^X ， H^Y 是独立从序列 S^X , S^Y 中学习到的，它们倾向于表示单个领域的用户部分偏好，正如前面所述，结合跨域偏好有助于更好的推荐。因此，受到信息最大化原理[15]的启发，复现论文作者提出了一个新的对比信息集目标，提高了单域表示和跨域表示之间的相关性。

3.5.1 单域和跨域原型表示

对于两个单域序列提取的物品原型表示，形式化如下：

$$\mathbf{o}_{\text{single}}^X = \text{Mean}(H^X), \quad \mathbf{o}_{\text{single}}^Y = \text{Mean}(H^Y) \quad (9)$$

其中， $\mathbf{o}_{\text{single}}^X \in \mathbb{R}^{1 \times d}$ ， $\mathbf{o}_{\text{single}}^Y \in \mathbb{R}^{1 \times d}$ 分别是 X 和 Y 领域的原型表示，其中， Mean 是平均操作。

对于跨域序列提取的物品原型表示，形式化如下：

$$\mathbf{o}_{\text{cross}}^X = \text{Mean}(\{\mathbf{h}_t : S_t \in \mathcal{X}\}), \quad \mathbf{o}_{\text{cross}}^Y = \text{Mean}(\{\mathbf{h}_t : S_t \in \mathcal{Y}\}), \quad (10)$$

其中，在跨域序列中，使用对应领域的物品平均作为对应领域的跨域原型表示。

3.5.2 信息最大化目标

为了使用对比学习增强表示，需要构建负例作为对比的目标，在复现论文中，作者将整个序列作为负例进行对比，形式化如下：

$$\begin{aligned} \hat{S}^X &= \text{Corrupt}^X(S) = [\hat{y}_1, x_1, x_2, \hat{y}_2, \dots], \\ \hat{S}^Y &= \text{Corrupt}^Y(S) = [y_1, \hat{x}_1, \hat{x}_2, y_2, \dots], \end{aligned} \quad (11)$$

其中， \hat{x}, \hat{y} 分别是对应领域中随机生成的物品。与之前用作训练的序列一致，使用公式(4)和(10)可以得到 $\hat{\mathbf{o}}_{\text{cross}}^X$ 和 $\hat{\mathbf{o}}_{\text{cross}}^Y$ 。复现论文作者使用如下公式来表示对比损失函数：

$$\mathcal{L}_{\text{disc}}^X = \sum_{(S^X, S^Y, S)_u \in \mathcal{S}} -\left(\log \mathcal{D}^X(\mathbf{o}_{\text{single}}^X, \mathbf{o}_{\text{cross}}^Y) + \log(1 - \mathcal{D}^X(\mathbf{o}_{\text{single}}^X, \hat{\mathbf{o}}_{\text{cross}}^Y))\right) \quad (12)$$

其中， \mathcal{D}^X 是一个判别器，使用一个双向线性映射来表示单域和跨域对结合表示，公式如下：

$$\mathcal{D}^X(\mathbf{o}_{\text{single}}^X, \mathbf{o}_{\text{cross}}^Y) = \sigma(\mathbf{o}_{\text{single}}^X W_{\text{disc}}^X (\mathbf{o}_{\text{cross}}^Y)^\top) \quad (13)$$

其中， $W_{\text{disc}}^X \in \mathbb{R}^{d \times d}$ 是一个可学习的矩阵，用于双向映射。

3.6 模型训练和评估

模型总体的损失函数是前面单域、跨域、对比损失的组合，公式如下：

$$\mathcal{L} = \lambda(\mathcal{L}_{\text{cross}} + \mathcal{L}_{\text{single}}^X + \mathcal{L}_{\text{single}}^Y) + (1 - \lambda)(\mathcal{L}_{\text{disc}}^X + \mathcal{L}_{\text{disc}}^Y) \quad (14)$$

其中， λ 是一个范围在 $[0, 1]$ 的参数，用来控制两个不同损失所占的权重。检验模型性能的预测公式如下（以 X 领域为例， Y 领域类似）：

$$\begin{aligned} &\arg\max_{x_i \in \mathcal{X}} P^X(x_i | S^X, S^Y, S), \quad \text{where} \\ P^X(x_i | S^X, S^Y, S) &= \text{Softmax}\left(\mathbf{h}_{|S|}^X W^X + \mathbf{h}_{|S|}^Y W^X\right)_{x_i} \end{aligned} \quad (15)$$

注意，以上公式要求同时使用了单域和跨域的物品表示，并且在混合序列上进行预测，使用 $\arg\max$ 函数可以取出预测的下一物品的概率最大的位置。

3.7 文本描述信息模块

物品的文本描述信息的引入在之前的研究中已经被证明有助于提升推荐信息，因此本文尝试在原模型中引入文本嵌入信息。首先使用预训练模型BERT提取文本信息，给定一个物品 i ，以及其文本描述 t_i ，文本描述包含了标题、分类、品牌和价格等信息。本文只使用物品的标题，分类和品牌作为文本，将其拼接作为物品文本描述，即 $t_i = [title; categories; brand]$ ，而;是拼接操作。然后使用BERT得到文本表示：

$$\mathbf{x}_i = \text{BERT}([\text{CLS}]; w_1, \dots, w_n) \quad (16)$$

其中， $\mathbf{x}_i \in \mathbb{R}^{d_w}$ 是对应的物品 i 经过BERT学习到的最后一层嵌入的文本特征， d_w 是输出的嵌入维度大小，[CLS]是使用BERT对应的编码器得到的一个特殊标记，这个标记融合了整个文本的信息。 w_i 是经过编码后的单词， n 是文本编码后的最大的长度。UniSRec [6]提到使用BERT提取的文本信息并不适合直接用于推荐任务，对于跨域场景，不同领域的文本信息差异过大，可能并不会带来提升，因此需要进行一个线性变化，尽量减小这种差异带来的负面影响，以下公式借用了UniSRec [6]的实现：

$$\tilde{\mathbf{x}}_i = (\mathbf{x}_i - \mathbf{b}) \cdot \mathbf{W}_t \quad (17)$$

其中， $\tilde{\mathbf{x}}_i \in \mathbb{R}^d$ 是经过线性变化后的特征表示， $\mathbf{b} \in \mathbb{R}^{d_w}$ 和 $\mathbf{W}_t \in \mathbb{R}^{d_w \times d}$ 是可学习的参数。在经过以上步骤之后，可以得到两个领域对应物品的文本特征和两个领域一起的文本特征， $E_t^X \in \mathbb{R}^{|\mathcal{X}| \times d}$, $E_t^Y \in \mathbb{R}^{|\mathcal{Y}| \times d}$, $E_t \in \mathbb{R}^{(|\mathcal{X}|+|\mathcal{Y}|) \times d}$ ，将文本特征与物品初始化嵌入矩阵结合：

$$\begin{aligned} \tilde{E}^X &= \text{Concat}(E^X, E_t^X) \mathbf{W}_{trans}^X + \mathbf{b}_{trans}^X \\ \tilde{E}^Y &= \text{Concat}(E^Y, E_t^Y) \mathbf{W}_{trans}^Y + \mathbf{b}_{trans}^Y \\ \tilde{E} &= \text{Concat}(E, E_t) \mathbf{W}_{trans} + \mathbf{b}_{trans} \end{aligned} \quad (18)$$

其中， $\mathbf{W}_{trans}^X \in \mathbb{R}^{(d+d) \times d}$ ， $\mathbf{W}_{trans}^Y \in \mathbb{R}^{(d+d) \times d}$ ， $\mathbf{W}_{trans} \in \mathbb{R}^{(d+d) \times d}$ ， $\mathbf{b}_{trans}^X \in \mathbb{R}^d$ ， $\mathbf{b}_{trans}^Y \in \mathbb{R}^d$ ， $\mathbf{b}_{trans} \in \mathbb{R}^d$ 均是可学习的参数， $\text{Concat}(\cdot, \cdot)$ 是特征拼接操作；将以上结合了文本特征的矩阵作为初始化物品矩阵进行训练。

4 复现细节

4.1 与已有开源代码对比

复现的这篇论文给出了参考源代码，使用源代码直接运行但并不能得到和论文中符合的结果，因此通过实验调参使其得到了和论文最相近的结果；并且将该模型在跨域序列数据集 [18]上进行实验，在模型原有基础上添加了物品的文本描述信息辅助推荐，在推荐性能上有一定提升。

4.2 实验环境搭建

为了保证实验结果不受环境不一致影响，参照原文的实验环境设置，其中，Python=3.7.9, PyTorch=1.6.0, Scipy = 1.5.2, Numpy = 1.19.1。原文实验在Intel Xeon E5 2.1GHz CPU, 256 RAM and a Tesla T4 16GB GPU的PC上运行，由于机器限制，本文在Linux机器上使用Tesla V100-PCIE-32GB上实验，后文中的实验结果均是在此机器上得到。

4.3 数据集介绍

原始数据和MGCL的数据集已在原文 [1]和MGCL [18]中已有介绍，本文不再赘述。两个数据集的划分方式不同，原始数据集按照比例划分，训练集、验证集、测试集比例分别为8:1:1。而非原文中提到的与SASRec [8]一致的留一法。原始数据集按照混合序列的方式存放，一个示例： $[x_1|timestamp|time, y_1|timestamp|time, x_2|timestamp|time, x_3|timestamp|time, y_2|timestamp|time, x_4|timestamp|time, \dots]$ 。两个领域的物品构建为一条序列，下一个预测的物品是哪个领域由最后一个物品决定。而MGCL的数据集按照SASRec的方式划分，每个用户在两个领域有一条序列，每条序列的倒数第二个作为验证物品，最后一个作为测试物品。因此将C²DSR在新数据集上实验，需要将新数据集转换为该模型能够加载的格式或修改模型的加载数据方式，本文采用的方式是将数据转换为模型允许加载的方式。

4.4 评估指标

原文采用平均倒数排名（Mean Reciprocal Rank, MRR），点击率（Hit Ratio, HR）@{1, 5, 10}，归一化累积折损收益（normalized discounted cumulative gain, NDCG）@{5, 10}作为评估指标。在评估阶段使用999个随机负采样的物品和预测的一个物品构建为一个测试用例，检验模型的性能。在MGCL中，采用HR@10和NDCG@10作为评估指标，采用100个按照流行度排序后的负样本和预测的一个物品构建为测试用例。在原始数据集上，遵循C²DSR的设置，在MGCL数据集上，遵循MGCL的设置。

4.5 创新点

引入了物品文本描述的信息，在一定程度上提升了多个领域的推荐性能。

5 实验结果分析

本部分对实验所得结果进行分析，表1是在原数据集上的结果，只保留了在NDCG@10, HR@10评估指标上的结果，按照论文中提到的超参和环境进行实验，由于实验结果达不到原论文中描述的结果，因此进行了调参，在dropout在{0.2, 0.3, 0.4, 0.5}选择， λ 在{0.6, 0.7, 0.8}中选择，batchSize在{128, 256, 512}中选择，最终将dropout设置为0.3，batchSize设为512，seed设置为3407，其余超参数与论文保持一致。表中将SASRec作为对比模型，是因为该模型是一个在序列推荐任务上很强的baseline，如果提出的模型性能落后太多，就说明该模型架构并不合适用于序列推荐任务。从表中的结果看出，虽然复现的结果与原论文并不能完全达到一致，但两者之间的误差是可以接受的。

表2是在MGCL数据集上进行的实验，其中虽然也有Movie和Book数据集，但是其数据并不是一样的。由于更换了数据集，可能需要重新进行调参才能达到最优性能。表中C²DSR的结果的参数设置：batchSize为128，hiddenUnits为128，seed是3407，maxlen增加到100，其他与原论文保持一致。另外在这组超参数下，引入文本信息进行推荐，从结果上可以分析出文本信息的引入在Movie和CD以及Movie和Book组成的跨域数据集上有性能的提升，但是，从表2中Book和CD跨域数据集可以看出，如果两个领域差异过大，引入文本信息进行跨域迁移的时候，会导致两个领域的性能有不同程度的下降。

表 1. 在原数据集上的对比结果

Methods	Food		Kitchen		Movie		Book		Entertainment		Education	
	NDCG@10	HR@10	NDCG@10	HR@10	NDCG@10	HR@10	NDCG@10	HR@10	NDCG@10	HR@10	NDCG@10	HR@10
SASRec	7.79	11.68	3.93	6.62	3.69	5.20	1.71	2.75	56.10	76.92	58.64	76.56
C ² DSR	9.71	14.54	4.94	8.18	5.76	9.55	2.45	3.75	59.35	79.08	61.56	79.21
Impl	9.77	14.05	4.81	7.76	6.74	10.67	2.41	3.98	60.02	80.58	65.05	79.87

表 2. 在MGCL数据集上的结果

Method	Book→Movie		Movie→Book		Book→CD		CD→Book		CD→Movie		Movie→CD	
	NDCG@10	HR@10	NDCG@10	HR@10	NDCG@10	HR@10	NDCG@10	HR@10	NDCG@10	HR@10	NDCG@10	HR@10
SASRec	0.1740	0.3126	0.1402	0.2597	0.1965	0.3539	0.1402	0.2597	0.1740	0.3126	0.1965	0.3539
C ² DSR	0.1905	0.2552	0.3876	0.4638	0.2072	0.2732	0.4071	0.4704	0.2701	0.3422	0.2412	0.3210
C ² DSR-Text	0.1969	0.2712	0.4059	0.4680	0.2018	0.2691	0.3059	0.4134	0.2805	0.3633	0.2522	0.3372
improved(%)	3.358	6.298	4.713	0.898	-2.609	-1.504	-24.871	-12.130	3.8509	6.1365	4.5667	5.0402

6 总结与展望

C²DSR同时利用序列内和序列间物品关系，联合学习单域和跨域用户偏好。主要包括一个图和注意力编码器，以同时利用序列内和序列间的物品关系，以及两个序列目标和一个对比学习目标，以共同学习和增强单域和跨域用户偏好。本文在复现论文的基础上，首先复现出了论文中相近的实验结果，并且迁移模型到MGCL [18]提供的数据集上实验，引入了物品的文本描述信息，在一定程度上提升了推荐性能。在未来将会探寻在跨域序列推荐领域上结合文本更加合适的方式、将目前只在两个领域上推荐扩展到多域推荐上，以及结合时间信息进行推荐等的研究方向。

参考文献

- [1] Jiangxia Cao, Xin Cong, Jiawei Sheng, Tingwen Liu, and Bin Wang. Contrastive cross-domain sequential recommendation. In *Proceedings of the 31st ACM International Conference on Information & Knowledge Management, CIKM '22*, page 138–147, New York, NY, USA, 2022.
- [2] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. volume 1, pages 4171–4186, 2019.
- [3] L. Guo, L. Tang, T. Chen, L. Zhu, Q.V.H. Nguyen, and H. Yin. Da-gcn: A domain-aware attentive graph convolution network for shared-account cross-domain sequential recommendation. pages 2483–2489, 2021.
- [4] X. He, K. Deng, X. Wang, Y. Li, Y. Zhang, and M. Wang. Lightgcn: Simplifying and powering graph convolution network for recommendation. pages 639–648, 2020.
- [5] B. Hidasi, A. Karatzoglou, L. Baltrunas, and D. Tikk. Session-based recommendations with recurrent neural networks. *Session-based Recommendations with Recurrent Neural Networks*, 2015.

- [6] Yupeng Hou, Shanlei Mu, Wayne Xin Zhao, Yaliang Li, Bolin Ding, and Ji-Rong Wen. Towards universal sequence representation learning for recommender systems. In *KDD*, 2022.
- [7] G. Hu, Y. Zhang, and Q. Yang. Conet: Collaborative cross networks for cross-domain recommendation. pages 667–676, 2018.
- [8] W.-C. Kang and J. McAuley. Self-attentive sequential recommendation. volume 2018-November, pages 197–206, 2018.
- [9] T.N. Kipf and M. Welling. Semi-supervised classification with graph convolutional networks. 2017.
- [10] M. Liu, J. Li, G. Li, and P. Pan. Cross domain recommendation via bi-directional transfer graph collaborative filtering networks. pages 885–894, 2020.
- [11] M. Ma, Z. Chen, P. Ren, J. Ma, Y. Lin, and M. De Rijke. Π -net: A parallel information-sharing network for shared-account cross-domain sequential recommendations. pages 685–694, 2019.
- [12] M. Ma, P. Ren, Z. Chen, Z. Ren, L. Zhao, P. Liu, J. Ma, and M. de Rijke. Mixed information flow for cross-domain sequential recommendations. *ACM Transactions on Knowledge Discovery from Data (TKDD)*, 16(4):1–32, 2022.
- [13] Shanlei Mu, Yupeng Hou, Wayne Xin Zhao, Yaliang Li, and Bolin Ding. Id-agnostic user behavior pre-training for sequential recommendation. In Yi Chang and Xiaofei Zhu, editors, *Information Retrieval*, pages 16–27, Cham, 2023. Springer Nature Switzerland.
- [14] A.P. Singh and G.J. Gordon. Relational learning via collective matrix factorization. pages 650–658, 2008.
- [15] J. Snell, K. Swersky, and R. Zemel. Prototypical networks for few-shot learning. volume 2017-December, pages 4078–4088, 2017.
- [16] Jiayi Tang and Ke Wang. Personalized top-n sequential recommendation via convolutional sequence embedding. In *Proceedings of the Eleventh ACM International Conference on Web Search and Data Mining, WSDM ’18*, page 565–573, New York, NY, USA, 2018. Association for Computing Machinery.
- [17] S. Wu, Y. Tang, Y. Zhu, L. Wang, X. Xie, and T. Tan. Session-based recommendation with graph neural networks. pages 346–353, 2019.
- [18] Zitao Xu, Weike Pan, and Zhong Ming. A multi-view graph contrastive learning framework for cross-domain sequential recommendation. In *Proceedings of the 17th ACM Conference on Recommender Systems, RecSys ’23*, page 491–501, New York, NY, USA, 2023.